

Курсовая работа

Классическое машинное обучение

Прогноз эффективности химических соединений против вируса гриппа

1. Постановка задачи

Цель работы - исследовать данные о химических соединениях и построить модели для прогнозирования показателей эффективности: IC50, CC50 и SI. Также решаются четыре задачи бинарной классификации: превышает ли IC50 медиану выборки, превышает ли CC50 медиану, превышает ли SI медиану и превышает ли SI значение 8.


Методологически важное решение: при обучении моделей из признаков удаляются все три колонки IC50, CC50 и SI. Это предотвращает утечку данных, потому что SI рассчитывается на основе IC50 и CC50.

2. Исследование данных (EDA)


Основная статистика целевых переменных

target	count	mean	std	min	50%	75%	max
IC50, mM	1001.0000	222.8052	402.1697	0.0035	46.5852	224.9759	4128.5294
CC50, mM	1001.0000	589.1107	642.8675	0.7008	411.0393	894.0892	4538.9762
SI	1001.0000	72.5088	684.4827	0.0115	3.8462	16.5667	15620.6000

В наборе 1001 объект и 213 числовых колонок после удаления служебного индекса. Целевые показатели имеют сильную асимметрию и выбросы: особенно SI, где максимум значительно выше медианы. Поэтому в части линейных моделей для регрессии применялось логарифмирование целевой переменной через $\log_{10}$.




Распределения на логарифмической шкале становятся более компактными, но выбросы остаются заметными.



Пропуски в данных: первые 10 колонок

feature	missing_count	missing_share
MinAbsPartialCharge	3	0.0030
MaxPartialCharge	3	0.0030
MinPartialCharge	3	0.0030
MaxAbsPartialCharge	3	0.0030
BCUT2D_MWHI	3	0.0030
BCUT2D_MRLOW	3	0.0030
BCUT2D_MRHI	3	0.0030
BCUT2D_LOGPLOW	3	0.0030
BCUT2D_LOGPHI	3	0.0030
BCUT2D_CHGLO	3	0.0030

Пропуски встречаются редко: максимальная доля около 0.3%. В моделях они заполняются медианой внутри Pipeline. Такой подход не удаляет объекты и устойчив к выбросам.



Корреляционный анализ показывает, что IC50, CC50 и SI связаны между собой, но для честного прогноза они не используются как признаки друг для друга. Среди дескрипторов есть сильно коррелирующие пары, поэтому в Pipeline используется VarianceThreshold, а в дальнейшем можно добавить более строгий отбор признаков.

Наиболее коррелирующие дескрипторы с целевыми переменными

target	feature	abs_corr	corr
IC50, mM	VSA_EState4	0.2742	-0.2742
IC50, mM	Chi2n	0.2571	-0.2571
IC50, mM	PEOE_VSA7	0.2560	-0.2560
IC50, mM	Chi2v	0.2492	-0.2492
IC50, mM	fr_Ar_NH	0.2455	0.2455
IC50, mM	fr_Nhpyrrole	0.2455	0.2455
IC50, mM	Chi4v	0.2436	-0.2436
IC50, mM	Chi4n	0.2435	-0.2435
IC50, mM	Chi3n	0.2397	-0.2397
IC50, mM	Chi3v	0.2378	-0.2378
IC50, mM	SlogP_VSA5	0.2364	-0.2364
IC50, mM	Chi1n	0.2298	-0.2298

3. Подход к моделированию

Для всех задач использован единый воспроизводимый подход: train/test split 80/20, random_state=42, заполнение пропусков медианой, удаление константных признаков, масштабирование для линейных моделей. Сравнивались базовая модель, линейная модель, случайный лес и градиентный бустинг. Для градиентного бустинга дополнительно выполнен компактный подбор гиперпараметров.

Регрессионные метрики: MAE, RMSE, R2. Основная метрика для выбора - RMSE, так как она сильнее штрафует крупные ошибки. Классификационные метрики: Accuracy, F1, Precision, Recall. Основная метрика для выбора - F1, так как классы могут быть несбалансированы, особенно для SI > 8.

4. Результаты регрессии

Регрессия IC50

task	model	MAE	RMSE	R2
regression_IC50, mM	RandomForest	233.5415	439.6946	0.4204
regression_IC50, mM	Tuned_GradientBoosting	237.2850	440.5238	0.4182
regression_IC50, mM	GradientBoosting	251.1927	463.0455	0.3572
regression_IC50, mM	Ridge_log_y	223.6775	480.8466	0.3068
regression_IC50, mM	DummyMean	315.1853	584.9037	-0.0256

Лучший результат для IC50: RandomForest; RMSE=439.695, R2=0.420.

Регрессия CC50

task	model	MAE	RMSE	R2
regression_CC50, mM	RandomForest	295.8559	461.4015	0.5894
regression_CC50, mM	Tuned_GradientBoosting	304.0819	466.7901	0.5797
regression_CC50, mM	GradientBoosting	348.3676	498.4544	0.5208
regression_CC50, mM	Ridge_log_y	368.0622	593.2467	0.3212
regression_CC50, mM	DummyMean	511.7293	723.0542	-0.0084

Лучший результат для CC50: RandomForest; RMSE=461.402, R2=0.589.

Регрессия SI

task	model	MAE	RMSE	R2
regression_SI	RandomForest	192.5245	1354.6558	0.0864
regression_SI	GradientBoosting	195.8015	1363.9154	0.0739
regression_SI	Tuned_GradientBoosting	196.7522	1365.9698	0.0711
regression_SI	Ridge_log_y	180.3373	1423.7976	-0.0092
regression_SI	DummyMean	204.7180	1423.9369	-0.0094

Лучший результат для SI: RandomForest; RMSE=1354.656, R2=0.086.

Вывод по регрессии: RandomForest оказался наиболее стабильным для всех трех целевых переменных. Для IC50 и CC50 качество умеренное, для SI качество низкое из-за экстремальных выбросов и нелинейной природы показателя. Для SI рекомендуется отдельно исследовать robust-подходы: winsorization, обучение на $\log_{1p}(SI)$, удаление экстремальных выбросов по согласованию с химиками.

5. Результаты классификации

IC50 > медианы

task	model	Accuracy	F1	Precision	Recall
------	-------	----------	----	-----------	--------

ic50_gt_median	Tuned_Gradient Boosting	0.7015	0.7321	0.6613	0.8200
ic50_gt_median	GradientBoosting	0.7015	0.7273	0.6667	0.8000
ic50_gt_median	RandomForest	0.6866	0.7097	0.6581	0.7700
ic50_gt_median	LogisticRegression	0.6816	0.7009	0.6579	0.7500
ic50_gt_median	DummyMostFrequent	0.5025	0.0000	0.0000	0.0000

Лучший результат: Tuned_GradientBoosting; Accuracy=0.701, F1=0.732.

CC50 > медианы

task	model	Accuracy	F1	Precision	Recall
cc50_gt_median	RandomForest	0.7463	0.7583	0.7207	0.8000
cc50_gt_median	LogisticRegression	0.7313	0.7429	0.7091	0.7800
cc50_gt_median	GradientBoosting	0.7114	0.7264	0.6875	0.7700
cc50_gt_median	Tuned_Gradient Boosting	0.7015	0.7170	0.6786	0.7600
cc50_gt_median	DummyMostFrequent	0.5025	0.0000	0.0000	0.0000

Лучший результат: RandomForest; Accuracy=0.746, F1=0.758.

SI > медианы

task	model	Accuracy	F1	Precision	Recall
si_gt_median	Tuned_Gradient Boosting	0.6716	0.6374	0.7073	0.5800
si_gt_median	GradientBoosting	0.6816	0.6322	0.7432	0.5500
si_gt_median	LogisticRegression	0.6169	0.6244	0.6095	0.6400
si_gt_median	RandomForest	0.6368	0.6138	0.6517	0.5800
si_gt_median	DummyMostFrequent	0.5025	0.0000	0.0000	0.0000

Лучший результат: Tuned_GradientBoosting; Accuracy=0.672, F1=0.637.

SI > 8

task	model	Accuracy	F1	Precision	Recall
si_gt_8	RandomForest	0.7015	0.5588	0.5938	0.5278
si_gt_8	GradientBoosting	0.7413	0.5439	0.7381	0.4306
si_gt_8	Tuned_Gradient Boosting	0.7363	0.5391	0.7209	0.4306
si_gt_8	LogisticRegression	0.6269	0.5342	0.4831	0.5972
si_gt_8	DummyMostFrequent	0.6418	0.0000	0.0000	0.0000

Лучший результат: RandomForest; Accuracy=0.701, F1=0.559.

Вывод по классификации: задачи IC50 > медианы и CC50 > медианы решаются лучше остальных. Задача SI > 8 сложнее из-за дисбаланса и природы SI как отношения двух величин. Для нее особенно важны Recall и Precision: высокая точность полезна, если нужно отбирать меньше кандидатов, а высокий Recall - если нельзя пропустить потенциально перспективные соединения.

6. Практические рекомендации

- Для первичного отбора соединений использовать ансамблевые модели RandomForest и GradientBoosting, так как они лучше линейных моделей учитывают нелинейные зависимости молекулярных дескрипторов.
- Не использовать IC50, CC50 и SI как признаки друг для друга в финальном прогнозе: это создает утечку и завышает качество.
- Для SI провести отдельное исследование выбросов. Часть экстремальных значений может быть химически важной, поэтому удалять их можно только после консультации с предметным специалистом.
- В следующей итерации добавить feature selection: удаление сильно коррелирующих дескрипторов, permutation importance, RFE или embedded importance из RandomForest.
- Для повышения качества попробовать более широкую кросс-валидацию и расширенные сетки гиперпараметров; текущие сетки компактны и рассчитаны на воспроизводимость на обычном ноутбуке.

7. Итог

Сводка лучших моделей

task	model	MAE	RMSE	R2	Accuracy	F1	Precision	Recall
regression_IC50, mM	RandomForest	233.5415	439.6946	0.4204				
regression_CC50, mM	RandomForest	295.8559	461.4015	0.5894				
regression_SI	RandomForest	192.5245	1354.6558	0.0864				
ic50_gt_median	Tuned_GradientBoosting				0.7015	0.7321	0.6613	0.8200
cc50_gt_median	RandomForest				0.7463	0.7583	0.7207	0.8000
si_gt_median	Tuned_GradientBoosting				0.6716	0.6374	0.7073	0.5800
si_gt_8	RandomForest				0.7015	0.5588	0.5938	0.5278

Работа показывает, что для конфиденциального набора из 1000 соединений можно построить воспроизводимый baseline по всем семи задачам. Наиболее перспективны ансамблевые методы, а ключевые направления улучшения - контроль выбросов, отбор признаков и расширенная настройка гиперпараметров.